

@WeRateDogs 数据分析

宠物狗评分的分析和可视化

Kipmin | 数据分析 (进阶) | 2019-02-18


评估数据

将数据文件用 pandas 读取到 jupyter 中,生成 3 张表,分别是:

twitter archive enhanced



image_prediction



tweet json

In [12]: **M** tweet_json. head (10)

Out[12]:

	id	retweet_count	favorite_count
0	892420643555336193	8287	37950
0	892177421306343426	6119	32593
0	891815181378084864	4054	24539
0	891689557279858688	8416	41293
0	891327558926688256	9129	39484
0	891087950875897856	3035	19839
0	890971913173991426	2010	11599
0	890729181411237888	18383	64028
0	890609185150312448	4175	27249
0	890240255349198849	7190	31269

将数据整合到一张表 twitter_archive_master 中

twitter_archive_master

```
<class 'pandas.core.frame.DataFrame'>
               Int64Index: 2064 entries, 0 to 2063
               Data columns (total 23 columns):
                             2064 non-null int64
                                     2064 non-null datetime64[ns]
               timestamp
                                     2064 non-null object
               source
               text
                                     2064 non-null object
               expanded_urls
                                     2064 non-null object
               rating_numerator
                                     2063 non-null float64
               rating_denominator 2064 non-null int64
                                     1421 non-null object
               name
                                     357 non-null object
               jpg_ur1
                                     2064 non-null object
               img_num
                                     2064 non-null int64
                                     2064 non-null object
               p1
               pl_conf
                                     2064 non-null float64
               pl_dog
                                     2064 non-null bool
               p2
                                     2064 non-null object
               p2_conf
                                     2064 non-null float64
               p2_dog
                                     2064 non-null bool
               рЗ
                                     2064 non-null object
               p3_conf
                                     2064 non-null float64
                                     2064 non-null bool
               p3_dog
                                     2064 non-null int64
               id
               retweet_count
                                     2064 non-null int64
               favorite_count
                                     2064 non-null int64
                \overset{-}{\text{bool}}(3), \text{ datetime} 64 [\text{ns}] (1), \text{ float} 64 (4), \text{ int} 64 (6), \text{ object} (9) 
               memory usage: 344.7+ KB
```

tweet id: 推特 ID

timestamp: 发推时间

source: 使用何种设备发送

text: 推文内容

expanded urls: 推文链接

rating_numerator: 评分分子

rating denominator: 评分分母

name: 宠物名

stage: 狗的地位分类

jpg url: 是预测的图像资源链接

img_num: 最可信的预测结果对应的图像编号 → 1 推特中的第一张图片

p1: 是算法对推特中图片的一号预测 → 金毛犬

p1_conf: 是算法的一号预测的可信度 → 95%

p1_dog: 是一号预测该图片是否属于"狗" (有可能是其他物种,比如熊、马等) →

True 真

p2: 是算法对推特中图片预测的第二种可能性 → 拉布拉多犬

p2_conf: 是算法的二号预测的可信度 → 1%

 $p2_dog:$ 是二号预测该图片是否属于"狗" → True 真

依次类推


id: 等于 tweet_id

retweet_count: 转发该推的数量

favorite_count: 点赞该推的数量


分析与可视化

- 评分高低和点赞数的关系




点赞和评分呈现正相关性

- 评分高低和转发数的关系



转发和评分呈正相关性

- 地位不同跟人们喜欢程度的关系



人们最喜欢 doggo 与 puppo 地位的狗,最不受欢迎的是 pupper 地位的狗

- 点赞超过平均数的狗中,什么品类的狗狗最多

使用 wordcloud 生成词云

```
    fav_mean = twitter_archive_master.favorite_count.mean()

2. variety = twitter_archive_master[twitter_archive_master.favorite_count >= fa
   v_mean]
3. data = variety.groupby(['p1']).count()
4.
   data = data.tweet_id.sort_values(ascending=False)
   variety_dict = data.to_dict()
7.
8.
   dog_image = np.array(Image.open('dog_white.jpg'))
9.
10. wc = WordCloud(background_color="white", max_words=200, mask=dog_image)
11. wc.generate_from_frequencies(variety_dict);
12.
13. plt.imshow(wc, interpolation='bilinear')
14. plt.axis("off")
15. plt.rcParams['figure.figsize'] = (30.0, 8.0)
16. plt.show()
```

